

Université Louis Pasteur
Département Science des Données

BUT SD – S2 – SAÉ 2.01

Conception et implémentation d'une base de données



**BUT SD - S2 - SAÉ 2.01 : Conception et implémentation d'une
base de données**

SAE Aviation

Exploitation d'une base de données relationnelle

Requêtes SQL, formulaires, états Access et analyse des résultats

Problématique : comment organiser et exploiter une base de données aéronautique pour transformer des données de vols brutes en indicateurs lisibles sur le trafic, les types d'aéronefs, les aéroports et les trajectoires ?

Étudiants	Ilyas El Battahi, Mattéo Augier, Yann Catelin Da Silva
Travail réalisé	Importation, structuration, requêtes SQL, formulaires, états Access et analyse des résultats
Date	Mercredi 27 mai 2026

Modèle relationnel

Requêtes SQL

Formulaires

États Access

Synthèse

Table des matières

1 Introduction	2
2 Présentation des données	2
3 Importation et nettoyage dans Access	3
4 Dépendances fonctionnelles	3
5 Normalisation et choix des clés	4
5.1 Clés primaires	4
5.2 Relations entre les tables	5
6 Implémentation et volumes obtenus	5
7 Requêtes d'analyse et visualisations	6
7.1 Top 10 des aéroports de départ	7
7.2 Top 10 des aéroports d'arrivée	8
7.3 Répartition par catégorie WTC	8
7.4 Typecodes les plus fréquents	9
7.5 Trajectoire reconstruite de l'AirbusTree	10
7.6 Messages d'identification par indicatif	11
8 Apport de la base relationnelle	11
9 Conclusion	12
A Annexe : extrait des requêtes SQL	13
B Annexe : dictionnaire simplifié des tables finales	13

1 Introduction

L'objectif de cette SAE est de construire une base de données relationnelle exploitable à partir de données aéronautiques hétérogènes. Les fichiers fournis ne constituent pas directement une base propre : ils proviennent de sources différentes, contiennent des champs répétitifs, des formats parfois difficiles à importer et des volumes très variables selon les tables.

Le travail réalisé consiste donc à passer de fichiers bruts à un modèle relationnel structuré. La démarche suivie est la suivante : importer les données sources, identifier les dépendances fonctionnelles, choisir des clés primaires, normaliser les tables, charger les données dans Access, puis produire des requêtes d'analyse et des visualisations.

Problématique

Comment organiser des données aéronautiques volumineuses dans une base relationnelle normalisée afin de permettre des analyses fiables sur les aéronefs, les vols, les messages et les trajectoires ?

Le choix d'Access est cohérent avec le contexte du projet : il permet de créer rapidement des tables, des index, des relations et des requêtes SQL tout en gardant une interface visuelle utile pour vérifier le schéma final.

2 Présentation des données

Les données utilisées proviennent de plusieurs fichiers. Chaque fichier joue un rôle différent dans la base finale : certains décrivent les aéronefs, d'autres les vols, les positions ou les messages reçus.

Tab. 1 : Sources de données utilisées

Source brute	Contenu principal	Rôle dans la base finale
AircraftTypes	Type d'aéronef, description, moteur, WTC, modèle	Référentiel des types d'aéronefs
FlightSample	Vols observés, indicatifs, aéroports de départ et d'arrivée	Table des vols et première identification des aéronefs
AirbusTree	Positions successives : latitude, longitude, vitesse, altitude	Trajectoire et vecteurs d'état
AllCall	Messages de type AllCall avec code icao24	Messages associés aux aéronefs
Identification	Messages d'identification et indicatifs	Association entre aéronefs et identités/callsigns

Les tables brutes ont été importées dans Access avec le préfixe R_. Ce préfixe signifie que les tables sont conservées comme données sources. Les tables finales normalisées utilisent le préfixe T_. Cette distinction permet de ne pas modifier les fichiers d'origine et de garder une séparation claire entre données brutes et données nettoyées.

3 Importation et nettoyage dans Access

L'importation a été réalisée fichier par fichier. Les fichiers CSV ont été importés avec le séparateur adapté, et les fichiers Excel ont été chargés directement dans Access. Pour éviter les erreurs de conversion, plusieurs champs numériques ont d'abord été importés comme texte puis convertis dans les requêtes d'insertion avec les fonctions Access Val(), Nz(), Trim() et IIf().

Difficultés rencontrées et solutions

- Certains champs de latitude, longitude ou altitude provoquaient des erreurs de conversion. Ils ont été sécurisés avec IIf(..., Null, Val(...)).
- Les tables de messages AllCall et Identification sont très volumineuses. Elles ont donc reçu des clés artificielles et des index sur icao24.
- Les champs textes ont été nettoyés avec Trim() pour supprimer les espaces parasites.
- Les valeurs manquantes ont été traitées avec Nz() ou conservées à Null lorsque l'information était réellement absente.

Un exemple de requête d'insertion sécurisée est présenté ci-dessous. Elle transforme une table brute en table finale exploitable.

Listing 1 : Exemple d'insertion nettoyée dans la table des vols

```
INSERT INTO T_Flight
(icao24, firstseen, takeofftime, lastseen, landingtime, callsign,
 estdepartureairport, airportofdeparture, estarrivalairport, airportofdestination)
SELECT
    Trim([icao24]),
    Val(Nz([firstseen],0)),
    Val(Nz([takeofftime],0)),
    Val(Nz([lastseen],0)),
    Val(Nz([landingtime],0)),
    Trim(Nz([callsign],'')),
    Trim(Nz([estdepartureairport],'')),
    Trim(Nz([airportofdeparture],'')),
    Trim(Nz([estarrivalairport],'')),
    Trim(Nz([airportofdestination],''))
FROM R_FlightSample
WHERE Trim(Nz([icao24],'')) <> '';
```

4 Dépendances fonctionnelles

La normalisation repose sur l'identification des dépendances fonctionnelles. Une dépendance fonctionnelle signifie qu'une information en détermine une autre. Par exemple, si un code icao24 identifie un aéronef, il peut déterminer son immatriculation ou son type lorsque ces informations sont disponibles.

Principales dépendances fonctionnelles retenues

- **Designator** détermine les caractéristiques techniques du type d'aéronef : description, nombre de moteurs, type de moteur et catégorie WTC.
- **TypeModelID** détermine une association précise entre un designator, un constructeur et un nom complet de modèle.
- **icao24** identifie un aéronef observé et peut donner son immatriculation, son modèle et son typecode lorsque ces champs sont disponibles.
- **FlightID** identifie un vol importé et détermine les champs de temps, d'indicatif et d'aéroports.
- **StateID** identifie une observation de position : latitude, longitude, vitesse, altitude et instant d'observation.
- **AllCallID** et **IdentificationID** identifient chacun un message unique dans les tables de messages.

La table brute des types d'aéronefs a été séparée en deux parties : une table pour les caractéristiques techniques stables du type, et une table de référence pour les associations entre designator, constructeur et nom complet du modèle. Cette séparation évite de mélanger plusieurs informations de granularité différente dans une seule table.

5 Normalisation et choix des clés

La base finale a été construite pour respecter une logique de troisième forme normale. L'objectif est de limiter les redondances, de rendre les mises à jour plus fiables et d'éviter les anomalies d'insertion ou de suppression.

5.1 Clés primaires

Tab. 2 : Clés primaires des tables finales

Table	Clé primaire	Justification
T_AircraftTypeCore	Designator	Identifie un type d'aéronef.
T_AircraftModelRef	TypeModelID	Clé artificielle, car plusieurs modèles peuvent être associés à un même designator.
T_Aircraft	icao24	Identifie un aéronef observé.
T_Flight	FlightID	Identifie chaque vol.
T_StateVector	StateID	Identifie chaque observation de position.
T_AllCall	AllCallID	Identifie chaque message AllCall.
T_Identification	IdentificationID	Identifie chaque message d'identification.

Certaines clés sont naturelles, comme icao24 ou Designator. D'autres sont artificielles, notamment dans les tables de messages, car les lignes représentent des événements et non des entités stables.

5.2 Relations entre les tables

Le modèle relationnel est organisé autour de deux tables principales : T_AircraftTypeCore, qui décrit les types d'aéronefs, et T_Aircraft, qui identifie les aéronefs observés. Les tables T_Flight, T_StateVector, T_AllCall et T_Identification sont reliées à T_Aircraft par le code icao24.




Fig. 1 : Schéma relationnel final construit dans Access

Le schéma contient sept tables finales et six relations principales. C'est cohérent : la table T_Aircraft joue un rôle central, tandis que T_AircraftTypeCore relie les informations de type et de modèle.

6 Implémentation et volumes obtenus

Après exécution des requêtes de création, d'insertion et d'indexation, les tables finales ont été contrôlées avec des requêtes Count(*). Les volumes obtenus sont résumés dans le tableau suivant.

Tab. 3 : Volumes des tables finales contrôlées dans Access

Table finale	Nombre de lignes
T_Aircraft	44 240
T_Flight	115 725
T_StateVector	16 141
T_AllCall	1 000 000
T_Identification	919 167
T_AircraftTypeCore	2 640

Ces résultats montrent que les tables de messages sont les plus volumineuses. Le choix de les séparer dans des tables spécifiques est donc important : il évite de surcharger la table des aéronefs et rend les requêtes plus lisibles.

Bilan de l'implémentation

La base finale sépare les entités stables, comme les aéronefs et les types d'aéronefs, des tables événementielles, comme les vols, les positions et les messages. Cette organisation permet d'interroger les données sans dupliquer inutilement les informations techniques des aéronefs.

7 Requêtes d'analyse et visualisations

Les visualisations ont été créées à partir des requêtes SELECT enregistrées dans Access puis exportées. Elles servent à vérifier que la base permet de produire des analyses concrètes : classement d'aéroports, répartition des types d'aéronefs, trajectoire et messages d'identification.

7.1 Top 10 des aéroports de départ




Fig. 2 : Aéroports de départ estimés les plus fréquents

L'aéroport KATL apparaît en tête des départs estimés avec 940 vols, suivi de KORD avec 906 vols. Les quatre premiers aéroports sont américains, ce qui indique que l'échantillon contient une forte composante nord-américaine. La présence de EHAM et LFPG montre aussi une partie européenne dans les données.

7.2 Top 10 des aéroports d'arrivée




Fig. 3 : Aéroports d'arrivée estimés les plus fréquents

Pour les arrivées, KORD est premier avec 1 046 vols, devant KATL avec 1 004 vols. Les mêmes grands hubs ressortent que pour les départs, ce qui est cohérent : les grands aéroports concentrent à la fois de nombreux départs et de nombreuses arrivées.

7.3 Répartition par catégorie WTC




Fig. 4 : Répartition des aéronefs selon la catégorie WTC

La catégorie M est la plus représentée avec 14 721 aéronefs, devant la catégorie L avec 5 551 aéronefs et la catégorie H avec 3 469 aéronefs. Cela signifie que l'échantillon contient surtout des avions de turbulence de sillage moyenne, ce qui correspond souvent à des appareils commerciaux courants.

7.4 Typecodes les plus fréquents




Fig. 5 : Typecodes les plus fréquents dans la table des aéronefs

Le typecode B738 est le plus fréquent avec 2 763 aéronefs, suivi de A320 avec 2 080 aéronefs. Les familles Boeing 737 et Airbus A320 ressortent fortement, ce qui est logique dans un jeu de données de trafic aérien civil.

7.5 Trajectoire reconstruite de l'AirbusTree




Fig. 6 : Trajectoire à partir des coordonnées longitude et latitude

Cette visualisation exploite les 16 141 positions de la table `T_StateVector`. Les points suivent une trajectoire progressive entre environ 6.64 et 11.66 degrés de longitude, et entre 48.91 et 55.96 degrés de latitude. Le graphique confirme que la table des positions peut être utilisée pour reconstruire un déplacement géographique.

7.6 Messages d'identification par indicatif




Fig. 7 : Indicatifs les plus présents dans les messages Identification

L'indicateur TEST1234 arrive en tête avec 7 984 messages. Il s'agit probablement d'une valeur de test ou d'un cas très répété dans les données. Les indicateurs suivants, comme RYR401, EZY29DJ ou JBU391, montrent que la table T_Identification peut être utilisée pour analyser la fréquence des messages par identifiant de vol.

8 Apport de la base relationnelle

La base relationnelle apporte trois améliorations principales par rapport aux fichiers bruts.

1. **Lisibilité** : les données sont séparées en tables ayant chacune un rôle précis.
2. **Fiabilité** : les clés primaires empêchent de confondre les entités, les vols et les messages.
3. **Exploitation** : les index sur icao24, les aéroports et les heures rendent les requêtes plus simples et plus rapides à comprendre.

La normalisation est particulièrement utile dans ce projet, car les données aéronautiques mélangent plusieurs niveaux d'information : un type d'aéronef, un aéronef précis, un vol, une position et un message ne représentent pas la même entité. Les mettre dans une seule grande table aurait provoqué de nombreuses répétitions et aurait rendu les analyses moins solides.

9 Conclusion

Cette SAE a permis de transformer des fichiers aéronautiques bruts en une base de données relationnelle structurée sous Access. Le modèle final contient des tables de référence, des tables d'événements, des clés primaires, des index et des relations logiques entre les entités.

Les visualisations produites confirment que la base est exploitable : elle permet d'identifier les aéroports les plus présents, les types d'aéronefs dominants, la répartition par catégorie WTC, la trajectoire d'un aéronef et les indicatifs les plus fréquents dans les messages.

Le travail montre donc qu'une base bien normalisée rend les données plus propres, plus compréhensibles et plus faciles à analyser. La suite possible serait d'ajouter des contrôles de qualité plus avancés, par exemple la détection automatique des valeurs incohérentes, ou de connecter la base à un outil de visualisation dynamique.

A Annexe : extrait des requêtes SQL

Le fichier complet des requêtes SQL est fourni séparément avec le rapport. Les extraits ci-dessous montrent les requêtes principales utilisées pour générer les visualisations.

Listing 2 : Top 10 des aéroports de départ

```
SELECT TOP 10
    estdepartureairport AS AeroportDepart,
    Count(*) AS NombreVols
FROM T_Flight
WHERE estdepartureairport <> ''
GROUP BY estdepartureairport
ORDER BY Count(*) DESC;
```

Listing 3 : Répartition par WTC

```
SELECT
    C.WTC,
    Count(*) AS NombreAvions
FROM T_Aircraft AS A
INNER JOIN T_AircraftTypeCore AS C
ON A.typecode = C.Designator
WHERE C.WTC <> ''
GROUP BY C.WTC
ORDER BY Count(*) DESC;
```

Listing 4 : Trajectoire AirbusTree

```
SELECT
    lon,
    lat,
    timeSeconds
FROM T_StateVector
WHERE lon Is Not Null
AND lat Is Not Null
ORDER BY timeSeconds;
```

B Annexe : dictionnaire simplifié des tables finales

Table	Rôle
T_AircraftTypeCore	Référentiel technique des types d'aéronefs : description, nombre de moteurs, type de moteur et WTC.
T_AircraftModelRef	Association entre designator, constructeur et nom complet de modèle.
T_Aircraft	Table centrale des aéronefs, identifiés par icao24.
T_Flight	Liste des vols observés, avec heures, indicatif et aéroports.
T_StateVector	Positions successives d'un aéronef : latitude, longitude, vitesse, altitude.

T_AllCall	Messages AllCall associés aux aéronefs.
T_Identification	Messages d'identification et indicatifs associés aux aéronefs.

Complément : états Access réalisés

Les requêtes ne servent pas uniquement à vérifier les données : elles ont aussi été utilisées pour produire des **états Access**. Ces états sont importants car ils transforment les résultats SQL en documents propres, imprimables et présentables. Ils gardent donc une trace claire de l'analyse effectuée dans la base.

État Access créé	Rôle dans le projet
E_Synthese_Base	Résume les volumes principaux de la base : nombre de vols, avions, identifiants et messages. Il donne une vision générale avant les analyses détaillées.
E_Repartition_WTC	Présente la répartition des avions par catégorie WTC. Il permet de voir rapidement quels types d'aéronefs dominent dans l'échantillon.
E_Top10_Arrivees	Classe les dix aéroports d'arrivée les plus fréquents. Il met en évidence les zones les plus représentées à l'arrivée.
E_Top10_Departs	Classe les dix aéroports de départ les plus fréquents. Il complète l'analyse du trafic en observant les points de départ principaux.
E_Top10_Identity	Affiche les identifiants les plus présents. Il aide à repérer les avions ou vols qui reviennent le plus souvent dans les données.
E_Top10_TypeCodes	Liste les types d'aéronefs les plus fréquents. Il relie la base aux caractéristiques techniques des avions.
E_Trajectoire_Resume	Résume une trajectoire avec nombre de positions, temps de début et de fin, coordonnées minimales/maximales et vitesses. Il montre comment les données de position peuvent devenir un indicateur de déplacement.

Lien avec le travail SQL : chaque état s'appuie sur une requête préparée dans Access. Les requêtes calculent, regroupent ou trient les données ; les états servent ensuite à rendre ces résultats lisibles pour la présentation. Le projet ne se limite donc pas à créer des tables : il montre toute la chaîne, de la donnée brute jusqu'à un rendu exploitable.

Réponse directe à la problématique

La problématique était de savoir comment exploiter une base de données aéronautique pour produire des informations utiles à partir de données brutes. Le travail réalisé répond à cette question en trois étapes.

Étape	Ce que cela apporte à la problématique
Structuration de la base	Les tables comme T_Flight, T_Aircraft, T_AircraftTypeCore, T_AllCall, T_Identification et T_StateVector séparent les informations selon leur rôle. Cela évite de mélanger les vols, les avions, les messages et les positions.
Requêtes d'analyse	Les requêtes de synthèse, de top 10, de répartition WTC et de trajectoire montrent que l'on peut extraire des indicateurs concrets : volumes de données, aéroports dominants, types d'avions et caractéristiques de déplacement.
États Access	Les états donnent une forme présentable aux résultats. Ils prouvent que les requêtes ne sont pas seulement techniques : elles peuvent être utilisées pour communiquer une analyse claire.

Conclusion de réponse : la base relationnelle permet de passer d'un ensemble de fichiers aéronautiques difficiles à lire à des résultats structurés. Les tables organisent la donnée, les requêtes répondent aux questions d'analyse et les états Access rendent ces réponses propres et exploitables. On peut donc comprendre le trafic aérien observé, repérer les aéroports les plus présents, identifier les catégories d'aéronefs et résumer une trajectoire à partir des positions enregistrées.

Cette réponse complète le rapport sans retirer ce qui avait déjà été fait : elle ajoute seulement les noms du groupe, l'université, les états réalisés et une conclusion plus explicite par rapport à la problématique.